

# Detección de Bots en la Red Social X Mediante Análisis a Nivel de Tweet

**Marvin Lisandro  
Sandi Calderón**

Escuela de Computación  
Universidad de Costa Rica  
San José, Costa Rica  
marvin.sandi@ucr.ac.cr

**Randy Yasiel  
Sancho Vásquez**

Escuela de Computación  
Universidad de Costa Rica  
San José, Costa Rica  
randy.sancho@ucr.ac.cr

**Marlon Esteban  
Murillo Quesada**

Escuela de Computación  
Universidad de Costa Rica  
San José, Costa Rica  
marlon.murilloquesada@ucr.ac.cr

**Resumen**—Este proyecto presenta un modelo híbrido basado en técnicas modernas de procesamiento de lenguaje natural y aprendizaje automático para la detección automatizada de cuentas bot en la red social Twitter. Utilizando un conjunto de datos amplio y diversificado, que incluye tanto texto de tweets como características numéricas de perfiles, el modelo combina una arquitectura de lenguaje profundo (RoBERTa) con redes neuronales para metadatos. Los resultados obtenidos muestran una precisión, recall y F1-score superiores al 99 %, evidenciando la efectividad y robustez del enfoque propuesto. Este trabajo contribuye a mejorar la identificación temprana y confiable de perfiles automatizados, con aplicaciones en la mitigación de desinformación y manipulación en plataformas digitales.

**Abstract**—This project presents a hybrid model based on modern natural language processing techniques and machine learning for automated bot account detection on the Twitter social network. Using a large and diverse dataset including both tweet text and numerical profile features, the model combines a deep language architecture (RoBERTa) with neural networks for metadata. The results demonstrate precision, recall, and F1-score above 99%, highlighting the effectiveness and robustness of the proposed approach. This work contributes to enhancing the early and reliable identification of automated profiles, with applications in mitigating misinformation and manipulation on digital platforms.

## I. CONTEXTO

Las redes sociales han transformado profundamente la manera en que las personas se comunican, se informan e interactúan entre sí. Twitter, en particular, se ha consolidado como una de las plataformas más influyentes en el ámbito de la comunicación digital, caracterizándose por su inmediatez, su brevedad y su capacidad de amplificación de mensajes. Estas cualidades han permitido que noticias, opiniones y tendencias se propaguen a una velocidad sin precedentes, alcanzando audiencias globales en cuestión de segundos.

No obstante, estas mismas fortalezas han sido aprovechadas de manera negativa. La simplicidad con la que se pueden crear y gestionar cuentas ha propiciado la proliferación de perfiles automatizados, conocidos como bots, que simulan comportamientos humanos para operar de forma encubierta dentro de la red. Estas cuentas no solo alteran métricas de interacción como retuits o seguidores, sino que también pueden desempeñar un papel crucial en la manipulación de la opinión pública, en la promoción de campañas políticas

o comerciales, y en la difusión masiva de desinformación. Estudios han estimado que entre el 9 % y el 15 % de los usuarios activos mensuales de Twitter son bots, lo que equivale a entre 28,7 y 47,9 millones de cuentas automatizadas [1]. Este fenómeno plantea serios desafíos en términos de autenticidad de la información, confianza en las redes sociales y seguridad digital.

## II. JUSTIFICACIÓN

La detección automatizada de cuentas maliciosas/bots en redes sociales es un desafío crítico en la era digital. Estos bots pueden manipular la opinión pública, distorsionar tendencias políticas, inflar artificialmente la popularidad de productos o candidatos, e incluso afectar la estabilidad financiera mediante la difusión de información fraudulenta. Su identificación no solo protege la integridad y fidelidad de las interacciones en línea, sino que también mitiga riesgos sociales y económicos. Nuestro proyecto busca contribuir a esta área mediante un modelo de aprendizaje automático capaz de distinguir comportamientos de bots a nivel de tweet, aprovechando un dataset diverso, muy amplio y validado académicamente.

### A. Disponibilidad de los Datos

El dataset utilizado, recopilado por Cresci y colaboradores [2], contiene más de catorce mil cuentas y más de dieciocho millones de tweets distribuidos en categorías diferenciadas: cuentas genuinas, spambots sociales/tradicionales y seguidores falsos. Además, posee una buena diversidad temporal (datos desde 2009 hasta 2014) y temática (promoción política, scams, aplicaciones pagas, etc.) que permitirá entrenar un modelo robusto, capaz de generalizar patrones en distintos contextos. La cantidad de datos es suficiente para evitar el sobreajuste, y al provenir de estudios previos, se garantiza su calidad sin necesidad de generar datos sintéticos.

### B. Aplicabilidad

El aprendizaje automático es especialmente útil para este problema, ya que los bots suelen exhibir patrones repetitivos en la frecuencia de publicaciones, palabras usadas, interacciones o metadatos. Nuestro enfoque a nivel de tweet nos va a permitir identificar comportamientos sospechosos, como el uso masivo de hashtags, enlaces fraudulentos o repetición de

contenido. Para esto, se emplearán técnicas de procesamiento de lenguaje natural que analizan el texto de los tweets, identificando características clave como palabras frecuentes, estructura gramatical, contexto, entre otros.

### C. Limitaciones Legales

Al tratarse de un proyecto académico, los datos se utilizarán exclusivamente con fines educativos, respetando los lineamientos éticos de investigaciones previas. Las herramientas empleadas (PyTorch entre ellas) son de acceso público. El impacto social podría ser significativo: un modelo funcional podría adaptarse en el futuro para plataformas que combaten la desinformación, contribuyendo a entornos digitales más transparentes.

### D. Robustez y Escalabilidad

La robustez del modelo se beneficia directamente del dataset anteriormente mencionado, ya que su diversidad en tipos de bots y su amplio volumen de tweets permiten capturar una variedad de patrones maliciosos. Esto reduce el riesgo de que el modelo solo funcione en casos específicos, mejorando su capacidad para generalizar en diferentes escenarios.

Para garantizar un rendimiento eficiente, se implementarán las siguientes estrategias:

- 1) **Procesamiento por lotes:** División del dataset en segmentos manejables para optimizar el uso de recursos computacionales.
- 2) **Paralelización:** Uso de múltiples núcleos en el cluster de la Universidad de Costa Rica para acelerar el entrenamiento.
- 3) **Selección de características:** Identificación de elementos relevantes mediante técnicas estadísticas y semánticas, lo que reduce la complejidad del modelo.

El enfoque técnico prioriza la eficiencia, permitiendo manejar grandes volúmenes de datos sin comprometer el rendimiento y sacando gran provecho de los recursos computacionales disponibles.

Además, el modelo fue capaz de alcanzar una precisión del **99,99 %** en el conjunto de prueba, demostrando la eficacia de un enfoque híbrido que combina el modelo de lenguaje RoBERTa con características numéricas estructuradas. Este resultado resalta la capacidad del modelo para generalizar y detectar patrones complejos en los datos, así como la validez de las estrategias de procesamiento y optimización implementadas para asegurar su escalabilidad y robustez.

### E. Explicabilidad

Para garantizar transparencia en las decisiones del modelo, se utilizarán métodos interpretativos como **saliency maps** adaptadas a texto. Esta técnica va a resaltar las palabras o frases en los tweets que más influyen en la clasificación, facilitando la validación de resultados y promoviendo la transparencia.

### F. Disponibilidad de Recursos

Contamos con un equipo de tres miembros y acceso a un cluster computacional proporcionado por la universidad, equipado con capacidades de almacenamiento y procesamiento paralelo. Esto garantiza la ejecución eficiente de etapas críticas como el entrenamiento de redes neuronales o el análisis de grandes volúmenes de texto.

## III. ANTECEDENTES

La detección de cuentas falsas en redes sociales ha sido objeto de múltiples investigaciones debido a su relevancia en la protección de la integridad digital, la prevención de la desinformación y el fortalecimiento de la confianza en las plataformas en línea. A continuación, se presenta un resumen de algunos enfoques destacados que abordan este desafío desde distintas perspectivas técnicas y metodológicas.

- [3] M. J. Ekosputra et al., “Supervised Machine Learning Algorithms to Detect Instagram Fake Accounts” 2021. Este estudio aborda el problema de los usuarios falsos en Instagram, que son utilizados para actividades maliciosas como suplantación de identidad, difusión de comentarios de odio o rumores. Se propone un enfoque de aprendizaje supervisado mediante algoritmos como regresión logística, Naive Bayes de Bernoulli, Random Forest, máquinas de vectores de soporte (SVM) y redes neuronales artificiales (ANN). Se realizan dos experimentos, destacando que Logistic Regression y Random Forest logran una precisión del 93 % tras la inclusión de nuevas características y el ajuste de parámetros.
- [4] Y. A. Rani et al., “Fake Account Detection Using ANN Based Model in Machine Learning” 2024. Con el objetivo de mitigar los riesgos relacionados con cuentas falsas —como la desinformación, el acoso o amenazas a la ciberseguridad— este proyecto desarrolla un sistema de detección basado en técnicas de aprendizaje automático. El modelo emplea ingeniería de características, preprocesamiento de datos y entrenamiento con algoritmos adecuados. Una vez desplegado, el sistema puede monitorear actividades sospechosas y alertar a los administradores, facilitando respuestas rápidas y cumplimiento legal.
- [5] F. C. Akyon and M. E. Kalfaoglu., “Instagram Fake and Automated Account Detection” 2022. El estudio se enfoca en la detección de cuentas falsas y automatizadas que contribuyen al **fake engagement** en Instagram. Se generan dos conjuntos de datos específicamente para este propósito. Se aplican algoritmos como Naive Bayes, regresión logística, SVM y redes neuronales, además de técnicas como SMOTENC y algoritmos genéticos sensibles al costo para corregir sesgos de datos. Los resultados muestran

tasas de precisión de 86 % para cuentas automatizadas y 96 % para cuentas falsas.

- [6] B. P. Kavin et al., “Machine Learning-Based Secure Data Acquisition for Fake Accounts Detection in Future Mobile Communication Network” 2022. Este trabajo destaca el problema del contenido no deseado y perfiles fraudulentos en redes sociales como Twitter, Facebook e Instagram. Se presenta un enfoque basado en inteligencia artificial para detectar contenido **spam**, utilizando algoritmos como máquinas de vectores de soporte, redes neuronales artificiales y Random Forest. Los resultados indican que el modelo basado en SVM presenta un mejor rendimiento en precisión, **recall** y medida F. La solución es útil para detectar imágenes falsas y contenido inapropiado.
- [7] S. Kudugunta and E. Ferrara., “Deep Neural Networks for Bot Detectio” 2018. Este artículo aborda la detección de **bots** en redes sociales —cuentas automáticas que se hacen pasar por usuarios reales— utilizando redes neuronales profundas con arquitectura LSTM contextual. El sistema combina metadatos y contenido textual de publicaciones para identificar cuentas automatizadas con alta precisión, incluso desde un solo **tweet**. La técnica también incluye sobremuestreo sintético para generar conjuntos de datos robustos a partir de muestras limitadas, alcanzando un AUC superior al 99 % en clasificación a nivel de cuenta.
- [8] Y. Wu et al., “A Novel Framework for Detecting Social Bots with Deep Neural Networks and Active Learning” 2020. Este estudio propone un marco innovador llamado DABot para la detección de **social bots** en plataformas como Sina Weibo. Se extraen 30 características, incluyendo metadatos, interacciones, contenido y tiempos, de las cuales nueve son novedosas. Se incorpora aprendizaje activo para ampliar los datos etiquetados y se implementa un modelo neuronal basado en ResNet, BiGRU y mecanismos de atención. Los resultados superan los **baselines** del estado del arte, alcanzando una precisión del 98.87 %.

#### IV. METODOLOGÍA

El desarrollo del proyecto se llevó a cabo siguiendo la metodología **CRISP-DM (Cross Industry Standard Process for Data Mining)**, la cual se adapta bien a proyectos de minería de datos y aprendizaje automático. A continuación, se describen las fases relevantes junto con detalles técnicos y fragmentos de código que ilustran la implementación.

##### A. Limpieza y Unificación del Dataset

1) *Dataset Original*: El dataset utilizado fue recopilado por Cresci et al. [2], estaba compuesto por múltiples fuentes categorizadas de la siguiente manera:

Cuadro I  
FUENTES DEL DATASET ORIGINAL

| Tipo de cuenta            | Usuarios | Tweets    | Año  |
|---------------------------|----------|-----------|------|
| Genuine accounts          | 3,474    | 8,377,522 | 2011 |
| Social spambots #1        | 991      | 1,610,176 | 2012 |
| Social spambots #2        | 3,457    | 428,542   | 2014 |
| Social spambots #3        | 464      | 1,418,626 | 2011 |
| Traditional spambots #1   | 1,000    | 145,094   | 2009 |
| Traditional spambots #2-4 | -        | -         | -    |
| Fake followers            | 3,351    | 196,027   | 2012 |

Los datasets utilizados se componen de distintos tipos de cuentas agrupadas en dos grandes categorías: reales y automatizadas. Las *genuine accounts* corresponden a cuentas verificadas y operadas por personas reales. Las cuentas etiquetadas como *bots* incluyen diversas variantes: los *social spambots #1, #2 y #3* representan cuentas falsas utilizadas para retuitear campañas políticas, promocionar aplicaciones móviles o productos comerciales; los *traditional spambots* corresponden a perfiles más antiguos que se dedicaban al envío masivo de contenido publicitario o fraudulento; y los *fake followers* son cuentas creadas con el propósito específico de inflar artificialmente la popularidad de otros perfiles.

2) *Subconjuntos Utilizados*: Para la experimentación se seleccionaron únicamente los siguientes subconjuntos:

- **Cuentas reales**: *Genuine accounts (reals)*
- **Cuentas bots**: combinación de *Social spambots #1, #2, #3, Traditional spambots #1 y Fake followers*

Se consolidaron dos archivos principales: *reals.csv* y *bots.csv*.

3) *Problemas Iniciales y Solución*: El archivo *reals.csv* presentaba corrupción de estructura ( $\approx 3$  GB), por lo que se utilizó EmEditor para eliminar manualmente líneas dañadas con número incorrecto de columnas, permitiendo su correcta carga con *pandas*.

4) *Reducción y Selección de Columnas*: Se conservaron únicamente las columnas más relevantes para la tarea de clasificación.

##### a) *Tweets*::

- *id* – Identificador del tweet
- *text* – Contenido textual
- *user\_id* – Relación con usuario
- *num\_hashtags, num\_urls, num\_mentions* – Métricas del contenido

##### b) *Users*::

- *id, screen\_name* – Identificadores
- *statuses\_count, followers\_count, friends\_count, favourites\_count, listed\_count*
- *lang, time\_zone, location*
- *default\_profile, default\_profile\_image, geo\_enabled, profile\_banner\_url, profile\_use\_background\_image*
- *description* – Biografía
- *bot* – Etiqueta binaria (0: humano, 1: bot)

### 5) Procesos Adicionales de Limpieza:

- 1) Eliminación de usuarios sin tweets (sin correspondencia en user\_id)
- 2) Eliminación de duplicados
- 3) Etiquetado con la columna bot
- 4) Unificación: tweets.csv, users.csv
- 5) Fusión final mediante tweets.user\_id = users.id
- 6) Resultado Final:
  - Archivo final: tweets\_x\_users.csv
  - Filas totales: 11,999,160
  - Columnas: 23
  - Uso: Entrenamiento y validación de modelos de detección de bots.

### B. Preparación y Procesamiento de datos

Partiendo del dataset ya consolidado y limpio, se diseñó una clase personalizada que extiende **Dataset** de PyTorch. Esta clase facilita la gestión y preprocesamiento de los datos, integrando tanto el análisis del texto de los tweets como el manejo de las variables numéricas relevantes para la detección de bots (ver algoritmo 1).

**Algoritmo 1** Código para el algoritmo de ordenamiento por residuos.

```
class TwitterBotDatasetHybrid(Dataset):
    def __init__(self, csv_file, tokenizer,
                 max_samples=None):
        self.data = pd.read_csv(csv_file)
        self.tokenizer = tokenizer
        # Filtrado opcional de muestras
        if max_samples:
            self.data = self.data.sample(n=
                max_samples, random_state=42).
                reset_index(drop=True)
        self.NUMERIC_COLS = ['num_hashtags', '
            num_urls', 'num_mentions', '
            statuses_count', 'followers_count',
            'friends_count', '
            favourites_count',
            'listed_count', '
            has_profile_banner'
        ]

    def __getitem__(self, idx):
        tweet = self.data.iloc[idx]['tweet']
        numeric_features = self.data.iloc[idx][self.
            NUMERIC_COLS].values.astype(np.float32)
        tokens = self.tokenizer(tweet, max_length
            =128, padding='max_length', truncation=
            True, return_tensors='pt')
        return tokens, numeric_features

    def __len__(self):
        return len(self.data)
```

### C. Diseño del Modelo

Se implementó un modelo híbrido basado en RoBERTa para el procesamiento del texto y una red neuronal para las características numéricas (ver figura 1). El modelo combina

ambas representaciones para realizar la clasificación binaria bot/no bot (ver algoritmo 2).

**Algoritmo 2** Código para el algoritmo de ordenamiento por residuos.

```
class BotClassifierHybrid(nn.Module):
    def __init__(self, n_numeric, text_model_name,
                 freeze_text=False):
        super().__init__()
        self.text_model = RobertaModel.
            from_pretrained(text_model_name)
        if freeze_text:
            for param in self.text_model.parameters
                ():
                param.requires_grad = False
        self.num_net = nn.Sequential(
            nn.Linear(n_numeric, 128),
            nn.ReLU(),
            nn.Dropout(0.2)
        )
        self.classifier = nn.Linear(self.text_model.
            config.hidden_size + 128, 2)

    def forward(self, input_ids, attention_mask,
                 numeric_features):
        text_output = self.text_model(input_ids=
            input_ids, attention_mask=attention_mask
        )
        text_emb = text_output.pooler_output
        num_emb = self.num_net(numeric_features)
        combined = torch.cat((text_emb, num_emb),
            dim=1)
        return self.classifier(combined)
```

### D. Entrenamiento y Evaluación

El modelo se entrenó utilizando PyTorch con técnicas de batch training y optimización AdamW. Se dividió el dataset en conjuntos de entrenamiento, validación y prueba con proporciones 70 %, 10 % y 20 %, respectivamente. Para cada época se calculó la precisión y la pérdida, y se implementó early stopping para evitar sobreajuste (ver algoritmo 3).

**Algoritmo 3** Código para el algoritmo de ordenamiento por residuos.

```
for epoch in range(num_epochs):
    model.train()
    for batch in train_loader:
        # Entrenamiento con batches
        optimizer.zero_grad()
        outputs = model(batch_input_ids,
            batch_attention_mask,
            batch_numeric_features)
        loss = criterion(outputs, batch_labels)
        loss.backward()
        optimizer.step()
```

### E. Evaluación del Modelo

La evaluación del modelo se realizó utilizando un conjunto de prueba independiente conformado por 160,000 ejemplos (20 % del dataset utilizado). Se emplearon métricas estándar como la precisión, recall, f1-score y accuracy para medir el desempeño.




Figura 1. Modelo de entrenamiento

Además, se utilizó una matriz de confusión para analizar los falsos positivos y falsos negativos, permitiendo una validación más granular del comportamiento del clasificador.

## V. RESULTADOS

### A. Métricas de Evaluación

Se utilizaron métricas ampliamente reconocidas para tareas de clasificación binaria:

- **Precisión:** proporción de predicciones positivas correctas.
- **Recall:** proporción de verdaderos positivos sobre todos los positivos reales.
- **F1-score:** media armónica entre precisión y recall.
- **Accuracy:** proporción total de predicciones correctas.

El rendimiento del modelo fue prácticamente perfecto, con un accuracy del 99.99 % (ver cuadro II).




Figura 2. Matriz de Confusión para 160000 líneas

Cuadro II  
DESEMPEÑO DEL MODELO EN EL CONJUNTO DE PRUEBA

| Clase        | Precisión   | Recall      | F1-score    | Support        |
|--------------|-------------|-------------|-------------|----------------|
| Humano       | 1.00        | 1.00        | 1.00        | 80,020         |
| Bot          | 1.00        | 1.00        | 1.00        | 79,980         |
| <b>Total</b> | <b>1.00</b> | <b>1.00</b> | <b>1.00</b> | <b>160,000</b> |

### B. Matriz de Confusión

La matriz de confusión (ver figura 2) muestra que el modelo cometió solo 9 errores en un total de 160,000 predicciones, respaldando la alta precisión y en la clasificación.

### C. Análisis Cualitativo

A continuación, se presentan ejemplos reales del conjunto de datos con sus respectivas predicciones. El objetivo es interpretar los factores textuales y numéricos que influyen en la decisión del modelo. En cada caso se considera el contenido del tweet, la información del perfil y las características asociadas.

#### a) Ejemplo 1 – Cuenta Clasificada como **Bot**:

**Tweet:** "Take twice as long to eat half as much. - Anonymous"

**Descripción del perfil:** "Need to scratch a mental itch? Check us out!"

**screen\_name:** MentalItch

**Características:** 10,465 publicaciones, 31,987 seguidores, 13,796 seguidos, has\_profile\_banner=0

**Predicción:** Bot (label=1)

Este caso representa una cuenta con alta actividad, un contenido genérico y posiblemente automatizado. La descripción y la estructura del tweet sugieren promoción impersonal.

b) *Ejemplo 2 – Cuenta Clasificada como Humano:*

**Tweet:** «USER>yeah totally riveting lol. Theme music was swing low sweet chariot....which just says it all!"

**Descripción del perfil:** "Political Reporter for Radio New Zealand. Based at Parliament's Press Gallery."

**screen\_name:** demelzaleslie

**Características:** 1,849 publicaciones, 1,846 seguidores, 776 seguidos, has\_profile\_banner=1

**Predicción:** Humano (label=0)

Este caso resalta varios indicadores asociados a actividad humana genuina: el uso de ironía y lenguaje coloquial ("lol", "which just says it all"), así como referencias culturales específicas ("swing low sweet chariot"), que requieren interpretación contextual. Estos factores lingüísticos son típicamente ausentes o mal ejecutados en bots automatizados.

## VI. DISCUSIÓN

Tal como se mostró, los resultados obtenidos muestran un desempeño excepcional del modelo híbrido basado en RoBERTa y características numéricas para la detección de cuentas tipo bot en Twitter. El modelo alcanzó una precisión, recall y F1-score muy elevados, lo que indica que es altamente efectivo para distinguir entre cuentas humanas y automatizadas.

Este alto rendimiento puede atribuirse principalmente a varios factores clave:

- 1) **Calidad y volumen del dataset:** La utilización de un dataset extenso y diverso, con más de 800,000 muestras en conjunto de entrenamiento, permitió al modelo aprender patrones representativos y generales, evitando el sobreajuste a casos específicos.
- 2) **Combinación de características textuales y numéricas:** El enfoque híbrido, que integra el análisis profundo del texto mediante RoBERTa junto con datos cuantitativos (metadatos y estadísticas de la cuenta), enriqueció la capacidad del modelo para capturar diferencias sutiles en el comportamiento y contenido.
- 3) **Estrategias de entrenamiento y validación robustas:** La división cuidadosa de los datos en entrenamiento, validación y prueba, junto con técnicas como el procesamiento por lotes y la paralelización, aseguraron un entrenamiento eficiente y fiable.

Sin embargo, es importante considerar ciertas limitaciones y aspectos para futuros trabajos:

- **Generalización a datos actuales:** Aunque el dataset utilizado es grande y variado, corresponde a datos recogidos entre 2009 y 2014. Las tácticas y comportamientos de bots pueden haber evolucionado desde entonces, por lo que se recomienda evaluar y adaptar el modelo con datos más recientes.
- **Detección a nivel de cuenta vs. tweet:** Este modelo opera a nivel de tweet individual, lo que permite detección rápida, pero podría beneficiarse de agregar contexto histórico o patrones de comportamiento longitudinal para mayor precisión en casos complejos.

## VII. CONCLUSIONES

En conclusión, el modelo desarrollado cumple con los objetivos propuestos, demostrando la viabilidad y efectividad de técnicas modernas de procesamiento de lenguaje natural combinadas con aprendizaje automático para la detección automatizada de bots en redes sociales.

Los resultados obtenidos evidencian que la integración de características textuales y numéricas, procesadas mediante una arquitectura híbrida basada en RoBERTa, permite distinguir con alta precisión entre cuentas humanas y automatizadas. Esto valida el enfoque metodológico empleado y resalta el potencial de las redes neuronales profundas para abordar desafíos complejos en entornos digitales.

Además, el uso de un dataset amplio y diversificado contribuyó a la robustez del modelo, garantizando su capacidad para generalizar en diferentes escenarios y minimizar falsos positivos y negativos. La escalabilidad y eficiencia logradas mediante el procesamiento por lotes y la paralelización en cluster aseguran que este enfoque pueda adaptarse a volúmenes masivos de datos reales.

Finalmente, el presente trabajo sienta una base sólida para futuros desarrollos que podrían incluir la implementación de técnicas explicativas más avanzadas, la extensión del modelo a otras plataformas sociales, y la integración en sistemas de monitoreo en tiempo real, contribuyendo así a la lucha contra la desinformación y la manipulación digital.

## REFERENCIAS

- [1] O. Varol, E. Ferrara, C. A. Davis, F. Menczer, and A. Flammini, "Online human-bot interactions: Detection, estimation, and characterization," 2017. [Online]. Available: <https://arxiv.org/abs/1703.03107>
- [2] S. Cresci, R. Di Pietro, M. Petrocchi, A. Spognardi, and M. Tesconi, "The paradigm-shift of social spambots: Evidence, theories, and tools for the arms race," in *Proceedings of the 26th International Conference on World Wide Web Companion*, ser. WWW '17 Companion. International World Wide Web Conferences Steering Committee, 2017, pp. 963–972. [Online]. Available: <https://doi.org/10.1145/3041021.3055135>
- [3] M. J. Ekosputra, A. Susanto, F. Haryanto, and D. Suhartono, "Supervised machine learning algorithms to detect instagram fake accounts," in *2021 4th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*, Dec 2021, pp. 396–400.
- [4] Y. A. Rani, G. Srividya, A. Balaram, K. H. Kumar, A. Kiran, and M. Silparaj, "Fake account detection using ann based model in machine learning," in *2024 International Conference on Science Technology Engineering and Management (ICSTEM)*, Apr 2024, pp. 1–7.
- [5] F. C. Kyon and M. E. Kalfaoglu, "Instagram fake and automated account detection," in *2022 Innovations in Intelligent Systems and Applications Conference (ASYU)*, Oct 2019, pp. 1–7.
- [6] B. Prabhu Kavim, S. Karki, S. Hemalatha, D. Singh, R. Vijayalakshmi, M. Thangamani, S. L. A. Haleem, D. Jose, V. Tirth, P. R. Kshirsagar, and A. G. Adigo, "Machine learning-based secure data acquisition for fake accounts detection in future mobile communication networks," *Wireless Communications and Mobile Computing*, vol. 2022, no. 1, p. 6356152, 2022. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1155/2022/6356152>
- [7] S. Kudugunta and E. Ferrara, "Deep neural networks for bot detection," *Information Sciences*, vol. 467, pp. 312–322, Aug 2018.
- [8] Y. Wu, Y. Fang, S. Shang, J. Jin, L. Wei, and H. Wang, "A novel framework for detecting social bots with deep neural networks and active learning," *Knowledge-Based Systems*, vol. 211, p. 106525, Oct 2020.